

Gan_Basic 과제 1 & 2

과제 1

"Generative Adversarial Networks" (GANs) 논문은 생성 모델링 분야에서 혁신적인 개념을 제시한 중요한 작품 중 하나입니다. 이 논문에서 GAN은 두 개의 신경망, 생성자 (Generator)와 판별자(Discriminator)로 구성되는 머신 러닝 아키텍처로 소개되며, 이 두 신경망 간의 경쟁과 협력을 통해 고품질의 데이터를 생성하는 방법을 제안합니다.

GAN의 핵심 아이디어는 생성자와 판별자 간의 게임 이론을 활용하여 생성자가 진짜 데이터와 구별하기 어려운 가짜 데이터를 생성하도록 하는 것입니다. 생성자는 점차 진짜 데이터와 유사한 데이터를 생성하도록 학습하고, 판별자는 실제 데이터와 생성된 데이터를 구별하는 데 사용됩니다. 이 두 신경망 간의 경쟁은 생성 모델의 성능을 향상시키는 데 중요한 역할을 합니다.

생성자 (Generator): 생성자는 가짜 데이터를 생성하는 역할을 합니다. 초기에는 무작위한 노이즈로부터 시작하여 훈련 중에 점차 실제 데이터와 비슷한 데이터를 생성하도록 학습됩니다. 생성자의 목표는 판별자를 속이는 것입니다. 즉, 생성된 데이터가 진짜 데이터처럼 보이도록 만드는 것이 중요합니다.

판별자 (Discriminator): 판별자는 생성자가 생성한 데이터와 실제 데이터를 구별하는 역할을 합니다. 판별자는 두 종류의 데이터를 받고 이를 식별하여 가짜 데이터와 진짜 데이터를 구별합니다. 판별자의 목표는 가짜 데이터와 진짜 데이터를 정확하게 구별하는 것입니다.

게임 이론: 생성자와 판별자 간의 상호 작용은 게임 이론의 개념을 기반으로 합니다. 여기서 게임은 두 플레이어 간의 경쟁과 협력을 나타냅니다. 생성자와 판별자는 서로 다른 목표를 가지고 있으며, 그들은 동시에 학습을 진행하면서 최적 전략을 찾으려고 합니다.

손실 함수 (Loss Function): 게임 이론에서는 생성자와 판별자의 성능을 나타내는 손실 함수가 사용됩니다. 생성자는 자신의 손실을 최소화하면서 판별자를 속이려고 노력하고, 판별자는 자신의 손실을 최소화하면서 가짜와 진짜 데이터를 올바르게 구별하려고 노력합니다. 이러한 경쟁과 학습을 통해 생성자와 판별자는 점차적으로 더 나은 성능을 발휘하게 됩니다.

이 논문의 가장 큰 기여 중 하나는 GAN이 다양한 응용 분야에서 성공적으로 사용될 수 있다는 것을 보여준 것입니다. 초기에는 이미지 생성에서 주로 사용되었지만, 현재는 음성, 텍스트, 비디오 등 다양한 데이터 유형을 생성하는 데 활용됩니다.

GAN은 데이터 생성 및 변환 작업을 수행하는 데 활용할 수 있는 강력한 도구로 입증되었으며, 계속해서 연구 및 발전되고 있습니다. 이러한 이유로 "Generative

Adversarial Networks" 논문은 딥러닝과 인공지능 분야에서 지속적으로 큰 관심을 받고 있으며, 미래에도 계속해서 중요한 주제로 남을 것으로 예상됩니다.

과제2

Generative Adversarial Networks(GANs)은 생성 모델의 성능을 평가하는 것이 중요한 과제 중 하나입니다. 아래에서 GAN의 성능을 평가하기 위한 4가지 주요 평가 방법을 자세히 설명하겠습니다.

1. 진짜 vs. 가짜 비율 (Real vs. Fake Ratio)

- **개요:** 이 방법은 생성된 샘플과 실제 데이터 샘플 간의 비율을 평가합니다. 이 비율이 높을수록 생성된 데이터가 실제 데이터와 더욱 유사하다고 판단됩니다.
- **계산 방법:** 생성자가 생성한 데이터와 실제 데이터를 판별자에게 제공하고, 판별자의 출력을 분석하여 진짜와 가짜 데이터의 비율을 계산합니다.
- **장점:** 간단하며 직관적인 방법이며, 생성 모델의 전반적인 성능을 대략적으로 파악할 수 있습니다.
- **단점:** 이 방법은 세부적인 데이터 분포를 고려하지 않으며, 생성된 데이터의 품질을 정확하게 평가하지 못할 수 있습니다.

2. Inception Score

- **개요:** Inception Score는 생성된 이미지의 품질과 다양성을 평가하는 지표입니다. 고정된 실제 데이터셋에 대한 이미지 분류 모델(Inception 모델)을 사용하여 계산됩니다.
- **계산 방법:** 생성된 이미지의 클래스 확률 분포를 계산하고, KL-다이버전스(Kullback-Leibler Divergence)를 사용하여 다양성과 품질을 측정합니다.
- **장점:** 이미지 생성에 중점을 두는 응용 분야에서 유용하며, 이미지 품질과 다양성을 동시에 고려합니다.
- **단점:** Inception Score는 특정 응용 분야에서만 유효하며, 다른 데이터 유형에는 적용하기 어려울 수 있습니다.

3. Frechet Inception Distance (FID)

- **개요:** FID는 생성된 이미지와 실제 이미지의 특징 공간에서의 유사성을 측정합니다. Inception 모델의 특징 벡터를 사용하여 계산됩니다.
- **계산 방법:** 생성된 이미지와 실제 이미지의 특징 벡터를 추출하고, 두 분포 간의 Fréchet 거리(Fréchet Distance)를 계산합니다.

- **장점:** 이미지 품질과 다양성을 모두 고려하며, Inception Score와 유사한 방식으로 사용됩니다.
- **단점:** 특징 벡터를 추출하기 위해 사전 훈련된 Inception 모델이 필요하며, 계산이 비교적 복잡합니다.

4. Wasserstein GAN (WGAN) 거리

- **개요:** Wasserstein GAN(WGAN) 거리는 GAN의 평가 및 훈련에 사용되는 대체 손실 함수 중 하나로, GAN 모델의 안정성 및 품질 향상에 기여하는 중요한 방법 중 하나입니다. WGAN 거리는 생성된 분포와 실제 데이터 분포 간의 거리를 측정하며, 기존 GAN의 주요 문제를 해결하기 위해 소개되었습니다.
- **계산 방법:** WGAN 거리는 Earth Mover's Distance(EMD) 또는 Wasserstein 거리로 알려진 두 분포 간의 거리를 계산합니다. EMD는 한 분포를 다른 분포로 이동하는 최소 비용을 나타내며, 생성된 데이터와 실제 데이터 간의 거리를 정량적으로 평가합니다. WGAN은 판별자와 생성자 간의 거리를 최소화하는 것을 목표로 하며, 이를 통해 안정적인 학습과 고품질 데이터 생성을 가능하게 합니다.
- **장점:** WGAN 거리는 기존 GAN의 모드 붕괴 문제와 학습 불안정성을 개선하는 데 도움이 되며, 생성된 데이터 분포를 실제 데이터 분포와 더 정확하게 근사화합니다. 이로 인해 더 나은 품질의 데이터 생성이 가능하며, 학습 중의 폭주 및 붕괴 문제를 줄여줍니다.
- **단점:** WGAN 거리를 계산하기 위해서는 계산 비용이 높을 수 있으며, 특히 고차원 데이터에서는 추가 계산 리소스가 필요할 수 있습니다. 또한 WGAN의 구현과 조정에는 몇 가지 추가적인 주의가 필요합니다.
⇒ 안정적인 학습과 고품질의 생성 데이터를 원하는 경우, WGAN과 관련된 변형 및 손실 함수를 사용하는 것이 일반적입니다.